

SIAMDA

Sistema Integrado de Análisis Multirresolución y Desempeño Académico

César Galindo López

Universidad Panamericana · Facultad de Empresariales, Ciudad UP

Gabriel Villafuerte C.

github.com/Gabriel44svg

2026

Idea central

SIAMDA combina un pipeline cuantitativo (calificaciones, parciales, estado de riesgo académico) con un pipeline cualitativo (respuestas abiertas de encuesta) para producir un índice de sentimiento por alumno mediante *embeddings* semánticos y la transformada discreta de onduleta (DWT). La eficiencia estadística de ese índice, entendido como estimador de un parámetro poblacional, se certifica comparando su varianza empírica contra la cota de Cramér–Rao bajo dos modelos de referencia (gaussiano y Laplaciano). Esta nota documenta la arquitectura del sistema y la formulación matemática exacta implementada en el código (`processing/datos.py`, `processing/nlp_wavelet.py`, `processing/cramer_rao.py`), sin reportar corridas experimentales sobre datos reales de curso: es una descripción de método, no un estudio de caso.

1. Motivación

Un curso genera dos tipos de señal sobre el desempeño de un alumno: una *cuantitativa* (calificaciones parciales, tareas, exposición) y una *cualitativa* (lo que el alumno escribe en una encuesta de retroalimentación abierta). La señal cuantitativa es la que normalmente se usa para detectar riesgo académico; la cualitativa suele leerse de forma impresionista, sin métrica. SIAMDA propone una métrica para la segunda señal —un índice de sentimiento $\hat{\theta} \in [-1, 1]$ por alumno, obtenido de sus respuestas de texto— y pregunta si esa métrica aporta información adicional sobre el riesgo académico, vía su correlación empírica con la calificación final.

2. Arquitectura del sistema

El sistema se organiza en cuatro módulos:

1. **Ingesta y normalización** (`datos.py`): lectura de archivos de calificaciones (CSV/Excel) con detección automática de columnas (número de cuenta, nombre, parciales `E1`, `E2`, ..., examen ponderado, tareas, exposición, validación), manejo de texto mixto en celdas no numéricas (“*te presentas a final*”, “*está en reposición*”, “*baja*”, etc.) y cómputo de una bandera binaria de riesgo.
2. **NLP y extracción wavelet** (`nlp_wavelet.py`): generación de *embeddings* de oración multilingües sobre las respuestas abiertas de la encuesta, y descomposición multirresolución de cada vector de embedding vía DWT.
3. **Validación teórica** (`cramer_rao.py`): cómputo de la información de Fisher y la cota de Cramér–Rao para el índice de sentimiento agregado, bajo los modelos gaussiano y Laplaciano, más una prueba de normalidad (Shapiro–Wilk) y una estimación bootstrap de la varianza empírica del estimador.
4. **Visualización interactiva**: interfaz Streamlit con páginas para carga de datos, métricas del curso, análisis de sentimiento y validación teórica, con interpretaciones automáticas en lenguaje natural para cada métrica.

3. Bandera de riesgo académico

Sea c_i la calificación final del alumno i y $e_i \in \{\text{Normal}, \dots\}$ su estado de validación (reposición, examen final, baja, etc.). El sistema define

$$r_i = \mathbf{1}\{c_i < 70\} \vee \mathbf{1}\{e_i \neq \text{Normal}\},$$

es decir, un alumno está en riesgo si su calificación cae por debajo del umbral aprobatorio (70) o si tiene un estado especial registrado, independientemente de la calificación numérica.

4. Índice de sentimiento por transformada wavelet

4.1. Embeddings y descomposición

Para cada alumno i , sea $x_i \in \mathbb{R}^d$ el embedding semántico de su respuesta de texto, obtenido con un modelo de *sentence-transformers* multilingüe (`paraphrase-multilingual-MiniLM-L12-v2`, $d = 384$), normalizado a norma unitaria. Tratando x_i como una señal discreta en $\mathbb{R}^d$ —indexada por las 384 coordenadas del embedding, en el orden en que el modelo las produce—, se aplica la transformada discreta de onduleta (DWT) con familia Daubechies 4 y nivel de descomposición $J = 3$ por defecto (acotado por `pywt.dwt_max_level(d, wavelet)` si d fuera más pequeño):

$$\text{wavedec}(x_i, J) = (c_A^{(i)}, c_{D,1}^{(i)}, \dots, c_{D,J}^{(i)}),$$

donde $c_A^{(i)}$ son los coeficientes de aproximación (contenido semántico global, de baja frecuencia) y $c_{D,j}^{(i)}$ los coeficientes de detalle en el nivel j (variación local, de alta frecuencia). Se definen las energías

$$E_i^{\text{apr}} = \|c_A^{(i)}\|_2^2, \quad E_i^{\text{det}} = \sum_{j=1}^J \|c_{D,j}^{(i)}\|_2^2.$$

Observación 4.1. La energía de aproximación captura contenido contextual estable (ideas organizadas, vocabulario consistente); la energía de detalle actúa como proxy de variación local abrupta en el embedding, interpretada aquí como carga emocional aguda en el texto.

Hueco metodológico: la DWT actúa sobre un eje sin orden natural

A diferencia de una señal temporal o de una secuencia de tokens, las 384 coordenadas de un embedding de *sentence-transformers* no tienen una noción intrínseca de adyacencia o frecuencia: son ejes de un espacio de características aprendido, y su orden es un artefacto de implementación del modelo, no una variable de la que el contenido semántico dependa continuamente. La DWT, en cambio, sí depende esencialmente del orden: permutar las coordenadas de x_i antes de aplicar `wavedec` produce en general valores distintos de E_i^{apr} y E_i^{det} para el *mismo* contenido semántico. Por lo tanto, la lectura “aproximación = contenido estable, detalle = carga emocional local” es una interpretación tomada por préstamo del uso estándar de la DWT en señales con estructura temporal/espacial genuina, no una propiedad derivada del significado de las coordenadas del embedding. Esto no invalida $\hat{\theta}_i$ como estadístico reproducible —para un orden de coordenadas fijo (el que produce el modelo), el índice es determinista y bien definido—, pero sí significa que su interpretación causal como “carga emocional” no está justificada por la matemática de la transformada en sí, sino que es una hipótesis de trabajo que requeriría validación externa (p. ej. contra anotación humana de las mismas respuestas) para sostenerse.

4.2. Índice de sentimiento

El índice de sentimiento del alumno i se define como

$$\hat{\theta}_i = \tanh\left(\frac{E_i^{\text{det}} - E_i^{\text{apr}}}{E_i^{\text{det}} + E_i^{\text{apr}} + \varepsilon}\right), \quad \varepsilon = 10^{-9},$$

de modo que $\hat{\theta}_i \in (-1, 1)$: valores cercanos a -1 indican energía concentrada en la aproximación (respuesta contextual, poca carga emocional local) y valores cercanos a $+1$ indican energía concentrada en los detalles (alta variabilidad emocional localizada).

5. Validación estadística: información de Fisher y cota de Cramér–Rao

Sea $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_N)$ la muestra de índices de sentimiento del grupo (los datos, no estimadores individuales de nada), tratada como N observaciones i.i.d. de una distribución con parámetro de localización μ (el sentimiento promedio del grupo), y $\bar{\theta} = \frac{1}{N} \sum_i \hat{\theta}_i$ el estimador de media muestral de μ . La cota de Cramér–Rao acota inferiormente la varianza de cualquier estimador insesgado de μ :

$$\text{Var}(\bar{\theta}) \geq \frac{1}{F(\mu)}, \quad F(\mu) = -\mathbb{E} \left[\frac{\partial^2}{\partial \mu^2} \ln p(X; \mu) \right].$$

Fórmulas clave

Modelo gaussiano. Bajo $\theta \sim \mathcal{N}(\mu, \sigma^2)$, con $\hat{\mu} = \bar{\theta}$ y $\hat{\sigma}^2$ la varianza muestral insesgada:

$$F(\mu) = \frac{N}{\hat{\sigma}^2}, \quad \text{CRB}_\mu = \frac{1}{F(\mu)} = \frac{\hat{\sigma}^2}{N}.$$

Modelo Laplaciano. Bajo $\theta \sim \text{Laplace}(\mu, b)$, con $\hat{\mu} = \text{mediana}(\hat{\theta})$ y $\hat{b} = \frac{1}{N} \sum_i |\hat{\theta}_i - \hat{\mu}|$:

$$F(\mu) = \frac{N}{\hat{b}^2}, \quad \text{CRB}_\mu = \frac{\hat{b}^2}{N}.$$

A diferencia del caso gaussiano, donde la media muestral alcanza la cota *exactamente* para todo N , la mediana muestral es el EMV de μ bajo el modelo Laplaciano y solo alcanza la cota *asintóticamente* ($N \rightarrow \infty$); para N finito su varianza puede exceder CRB_μ . **Eficiencia empírica del estimador (EES).** Con $\widehat{\text{Var}}(\bar{\theta})$ estimada por *bootstrap* ($B = 500$ remuestreos con reemplazo):

$$\text{EES} = \min \left(\frac{\text{CRB}_\mu}{\widehat{\text{Var}}(\bar{\theta})}, 1 \right).$$

El sistema complementa este cómputo con una prueba de normalidad de Shapiro–Wilk sobre $\hat{\theta}$: si el valor p resultante es menor a 0.05, se recomienda reportar el modelo Laplaciano (más robusto a colas pesadas) en lugar del gaussiano, y usar la mediana muestral —el estimador óptimo bajo ese modelo— en vez de la media.

Observación 5.1. La cota de Cramér–Rao certifica algo preciso y limitado: qué tan cerca está la *media muestral* de $\hat{\theta}$ de ser un estimador óptimo de sí misma bajo un modelo paramétrico supuesto. No certifica que $\hat{\theta}$ mida “sentimiento real” correctamente, ni sustituye una validación externa (p.ej. contra anotación humana) del índice.

Hueco: qué NO certifica esta verificación

Bajo el modelo gaussiano con σ^2 desconocida y estimada por $\hat{\sigma}^2$, la media muestral es el estimador insesgado de varianza mínima de μ para todo N (Lehmann–Scheffé), con $\text{Var}(\bar{\theta}) = \sigma^2/N$ exactamente. Es decir, bajo ese modelo la eficiencia es 1 por construcción, no por mérito del pipeline NLP-wavelet: no hay ningún estimador alternativo de μ que pudiera ganarle a la media muestral. La comparación que hace el sistema — $\text{CRB}_\mu = \hat{\sigma}^2/N$ contra $\widehat{\text{Var}}(\bar{\theta})$ estimada por *bootstrap sobre la misma muestra*— es, en el límite de N grande, una comparación entre dos maneras de estimar la *misma* cantidad (σ^2/N) a partir de los *mismos* datos: la fórmula normal con $\hat{\sigma}^2$ plug-in, y el remuestreo. Que ambas coincidan ($\text{EES} \approx 1$) es entonces, en gran medida, una prueba de consistencia numérica entre bootstrap y la fórmula asintótica de la varianza de la media —algo que ocurre para casi cualquier muestra razonablemente grande, independientemente de qué tan bien el pipeline de embeddings y wavelets capture sentimiento real—, y *no* es evidencia de que “el pipeline NLP-wavelet extrae la máxima información posible del texto”, como sugiere el texto de interpretación de la interfaz (`interpretar_crb` en `interpretacion.py`). Verificar eso último exigiría comparar $\hat{\theta}$ contra una pipeline de extracción de características alternativa (o contra anotación humana) sobre el mismo texto, no solo verificar que la media muestral de $\hat{\theta}$ es un buen estimador de sí misma.

6. Correlación con desempeño académico

Como paso final del análisis, el sistema calcula el coeficiente de correlación de Pearson r entre $\hat{\theta}_i$ y la calificación c_i de cada alumno, junto con su valor p asociado y el tamaño de muestra N . Una correlación negativa significativa ($r < 0$, $p < 0.05$) se interpreta como evidencia de que mayor carga emocional en las respuestas se asocia con menor desempeño; una correlación positiva significativa se interpreta como posible motivación extrínseca. El sistema clasifica la fuerza de la asociación en umbrales ($|r| \geq 0.6$ fuerte, $|r| \geq 0.3$ moderada, $|r| < 0.3$ débil) y explícitamente reporta cuando la correlación no es significativa, sin forzar una narrativa de riesgo donde no hay evidencia estadística.

Alcance y limitaciones

SIAMDA es una herramienta de apoyo a la decisión docente, no un instrumento diagnóstico automatizado. El índice $\hat{\theta}$ depende del modelo de embeddings elegido, de la familia y nivel de la wavelet, y del tamaño de la encuesta; con $N < 30$ las estimaciones bootstrap de varianza son inestables y el propio sistema advierte de ello en la interfaz. Las interpretaciones textuales que genera el módulo `interpretacion.py` son sugerencias de lectura, no conclusiones definitivas, y deben cotejarse con el criterio del docente y, cuando el caso lo amerite, con apoyo psicopedagógico institucional.

Implementación

Interfaz Streamlit (`app.py`) con cuatro páginas modulares (`pages/carga.py`, `pages/metricas.py`, `pages/sentimiento.py`, `pages/validacion.py`); `sentence-transformers` para embeddings, `PyWavelets` para la DWT, `scipy.stats` para Shapiro–Wilk y correlación de Pearson, `plotly` para visualización interactiva (incluyendo histograma bootstrap de $\bar{\theta}$ con bandas $\pm\sqrt{\text{CRB}}$, comparación de varianzas, y gráfica Q–Q de $\hat{\theta}$ contra la normal). Código y datos de ejemplo en github.com/Gabriel44svg/Galindo-C.-J.-y-Villafuerte-C.-G.-2026-.SIAMDA.

7. Conclusión

SIAMDA integra dos señales de un curso —calificaciones y respuestas abiertas de encuesta— bajo un mismo tablero, y añade a la segunda una métrica reproducible ($\hat{\theta}$, vía embeddings y DWT) junto con su certificado estadístico de eficiencia (información de Fisher y cota de Cramér–Rao, bajo modelos gaussiano y Laplaciano). El resultado es un sistema de alerta temprana que hace explícito, en vez de impresionista, el vínculo entre el tono de las respuestas de un grupo y su desempeño, y que reporta honestamente cuándo esa correlación no es estadísticamente significativa.