

# Sistema Integrado de Análisis Multirresolución y Desempeño Académico

Un índice de sentimiento con verificación estadística explícita de su eficiencia —y de sus límites—, vía embeddings y transformada wavelet

César Galindo López

Universidad Panamericana · Facultad de Empresariales, Ciudad UP

Gabriel Villafuerte C.

[github.com/Gabriel44svg](https://github.com/Gabriel44svg)

2026

## Resumen

Presentamos un sistema que combina la señal cuantitativa de un curso (calificaciones, parciales, estado de riesgo) con la señal cualitativa de una encuesta de retroalimentación abierta, produciendo para esta última un índice de sentimiento por alumno  $\hat{\theta} \in (-1, 1)$ : cada respuesta se convierte en una señal escalar indexada por posición de token (proyectando el embedding contextual de cada palabra sobre el embedding de oración), que se descompone con la transformada discreta de onduleta (DWT) en un componente de tendencia global y uno de fluctuación local. Acompañamos  $\hat{\theta}$  de una verificación estadística explícita —información de Fisher y cota de Cramér–Rao bajo los modelos gaussiano y Laplaciano— y mostramos, con simulaciones, exactamente qué certifica esa verificación y qué no. No reportamos corridas sobre datos reales de curso: este es un artículo de método, acompañado de simulaciones ilustrativas explícitamente etiquetadas como tales, no un estudio de caso.

**Palabras clave:** analítica académica, alerta temprana, análisis de sentimiento, transformada wavelet, información de Fisher, cota de Cramér–Rao.

## 1. Introducción

Un curso genera dos tipos de señal sobre el desempeño de un alumno: una *cuantitativa* (calificaciones parciales, tareas, exposición) y una *cualitativa* (lo que el alumno escribe en una encuesta de retroalimentación abierta). La señal cuantitativa es la que normalmente se usa para detectar riesgo académico; la cualitativa suele leerse de forma impresionista, sin métrica. Este trabajo propone una métrica para la segunda señal y pregunta si aporta información adicional sobre el riesgo académico, vía su correlación empírica con la calificación final.

La construcción de  $\hat{\theta}$  combina dos ingredientes bien establecidos por separado: *embeddings* contextuales de oración obtenidos con redes tipo Siamese-BERT [8], y la transformada discreta de onduleta como herramienta de análisis multirresolución de señales [7]. Lo

que el sistema añade es una capa de validación estadística explícita del estimador de sentimiento agregado del grupo, apoyada en la teoría clásica de eficiencia de estimadores [1, 2, 3], complementada con una prueba de normalidad [4] y una estimación de varianza por remuestreo [5]. La contribución de este artículo no es ninguno de esos ingredientes por separado, sino documentar con precisión qué certifica —y, sobre todo, qué *no* certifica— su combinación, algo que la primera versión de nuestra propia implementación afirmaba de forma imprecisa (sección 3.3).

## 2. Arquitectura del sistema

El sistema se organiza en cuatro módulos:

1. **Ingesta y normalización** (`datos.py`): lectura de archivos de calificaciones (CSV/Excel) con detección automática de columnas (número de cuenta, nombre, parciales `E1`, `E2`, ..., examen ponderado, tareas, exposición, validación), manejo de texto mixto en celdas no numéricas (“*te presentas a final*”, “*está en reposición*”, “*baja*”, etc.) y cómputo de una bandera binaria de riesgo.
2. **NLP y extracción wavelet** (`nlp_wavelet.py`): embeddings de oración y de token (*sentence-transformers* multilingüe) sobre las respuestas abiertas de la encuesta, y descomposición multirresolución de la señal posicional resultante vía DWT.
3. **Validación teórica** (`cramer_rao.py`): información de Fisher y cota de Cramér–Rao para el índice de sentimiento agregado, bajo los modelos gaussiano y Laplaciano, más prueba de normalidad (Shapiro–Wilk) y estimación bootstrap de la varianza del estimador.
4. **Visualización interactiva**: interfaz Streamlit con páginas para carga de datos, métricas del curso, análisis de sentimiento y validación teórica, con interpretaciones automáticas en lenguaje natural para cada métrica.

## 3. Métodos

### 3.1. Bandera de riesgo académico

Sea  $c_i$  la calificación final del alumno  $i$  y  $e_i \in \{\text{Normal}, \dots\}$  su estado de validación (reposición, examen final, baja, etc.). El sistema define

$$r_i = \mathbf{1}\{c_i < 70\} \vee \mathbf{1}\{e_i \neq \text{Normal}\},$$

es decir, un alumno está en riesgo si su calificación cae por debajo del umbral aprobatorio (70) o si tiene un estado especial registrado, independientemente de la calificación numérica.

### 3.2. Índice de sentimiento por transformada wavelet

Para cada alumno  $i$ , el modelo de *sentence-transformers* multilingüe (*paraphrase-multilingual-MiniLM-L1* dimensión  $d = 384$ ) [8] produce, en un solo *forward pass*: el embedding de oración  $x_i \in \mathbb{R}^d$  (normalizado a norma unitaria) y, para cada token  $t = 1, \dots, L_i$  de la respuesta, un embedding contextual  $u_{i,t} \in \mathbb{R}^d$ . A partir de estos se construye una señal escalar *indexada por posición del token en el texto* —un eje con adyacencia temporal genuina, a diferencia de las coordenadas del embedding—, proyectando cada token sobre la dirección semántica global de la respuesta:

$$s_i(t) = \langle u_{i,t}, x_i \rangle, \quad t = 1, \dots, L_i.$$

Sobre esta señal 1D se aplica la transformada discreta de onduleta [7] con familia Daubechies 4 y nivel de descomposición  $J = 3$  por defecto, acotado en la práctica por `min(pywt.dwt_max_level(L_i, wavelet))` —la respuesta más corta del lote, no una dimensión fija—:

$$\text{wavedec}(s_i, J) = (c_A^{(i)}, c_{D,1}^{(i)}, \dots, c_{D,J}^{(i)}),$$

donde  $c_A^{(i)}$  son los coeficientes de aproximación (tendencia global de la respuesta, de baja frecuencia *en la posición*) y  $c_{D,j}^{(i)}$  los coeficientes de detalle en el nivel  $j$  (fluctuación local palabra a palabra, de alta frecuencia). Se definen las energías

$$E_i^{\text{apr}} = \|c_A^{(i)}\|_2^2, \quad E_i^{\text{det}} = \sum_{j=1}^J \|c_{D,j}^{(i)}\|_2^2,$$

y el índice de sentimiento del alumno  $i$  se define como

$$\hat{\theta}_i = \tanh\left(\frac{E_i^{\text{det}} - E_i^{\text{apr}}}{E_i^{\text{det}} + E_i^{\text{apr}} + \varepsilon}\right), \quad \varepsilon = 10^{-9},$$

de modo que  $\hat{\theta}_i \in (-1, 1)$ : valores cercanos a  $-1$  indican energía concentrada en la aproximación (respuesta contextual, poca fluctuación local) y valores cercanos a  $+1$  indican energía concentrada en los detalles (alta variabilidad local, interpretada aquí como carga emocional puntual).

#### Corrección de diseño

En una versión anterior de este pipeline, la DWT se aplicaba directamente sobre las 384 coordenadas de  $x_i$ , tratándolas como si fueran una señal temporal. Esas coordenadas son ejes de un espacio de características aprendido sin orden ni adyacencia intrínsecos: permutarlas no cambia el significado del texto, pero sí cambiaba  $E_i^{\text{apr}}$  y  $E_i^{\text{det}}$  bajo esa versión, de modo que la lectura “aproximación = contenido estable, detalle = emoción” no estaba justificada por la matemática de la transformada. La formulación de arriba —proyectar cada token sobre el embedding de oración y aplicar la DWT sobre la *posición del token*— usa un eje con estructura secuencial genuina, para el cual la separación de la DWT en tendencia global (apro-

ximación) y fluctuación local (detalle) sí tiene el respaldo habitual de la teoría de wavelets [7]. Código: `processing/nlp_wavelet.py` (`obtener_embeddings_token, señal_por_posicion, aplicar_dwt_posicional`).

### 3.3. Validación estadística: información de Fisher y cota de Cramér–Rao

Sea  $\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_N)$  la muestra de índices de sentimiento del grupo (los datos, no estimadores individuales de nada), tratada como  $N$  observaciones i.i.d. de una distribución con parámetro de localización  $\mu$  (el sentimiento promedio del grupo), y  $\bar{\theta} = \frac{1}{N} \sum_i \hat{\theta}_i$  el estimador de media muestral de  $\mu$ . La cota de Cramér–Rao [1, 2, 3] acota inferiormente la varianza de cualquier estimador insesgado de  $\mu$ :

$$\text{Var}(\bar{\theta}) \geq \frac{1}{F(\mu)}, \quad F(\mu) = -\mathbb{E} \left[ \frac{\partial^2}{\partial \mu^2} \ln p(X; \mu) \right],$$

donde  $X = (\hat{\theta}_1, \dots, \hat{\theta}_N)$  denota la muestra completa (de modo que  $p(X; \mu) = \prod_i p(\hat{\theta}_i; \mu)$  y  $F(\mu)$  ya incorpora el factor  $N$ , como en las fórmulas explícitas de abajo).

#### Fórmulas clave

**Modelo gaussiano.** Bajo  $\theta \sim \mathcal{N}(\mu, \sigma^2)$ , con  $\hat{\mu} = \bar{\theta}$  y  $\hat{\sigma}^2$  la varianza muestral insesgada:

$$F(\mu) = \frac{N}{\hat{\sigma}^2}, \quad \text{CRB}_\mu = \frac{1}{F(\mu)} = \frac{\hat{\sigma}^2}{N}.$$

**Modelo Laplaciano.** Bajo  $\theta \sim \text{Laplace}(\mu, b)$ , con  $\hat{\mu} = \text{mediana}(\hat{\theta})$  y  $\hat{b} = \frac{1}{N} \sum_i |\hat{\theta}_i - \hat{\mu}|$ :

$$F(\mu) = \frac{N}{\hat{b}^2}, \quad \text{CRB}_\mu = \frac{\hat{b}^2}{N}.$$

A diferencia del caso gaussiano, donde la media muestral alcanza la cota *exactamente* para todo  $N$ , la mediana muestral es el EMV de  $\mu$  bajo el modelo Laplaciano y solo alcanza la cota *asintóticamente* ( $N \rightarrow \infty$ ); para  $N$  finito su varianza puede exceder  $\text{CRB}_\mu$ . **Eficiencia empírica del estimador (EES).** Con  $\widehat{\text{Var}}(\bar{\theta})$  estimada por *bootstrap* [5] ( $B = 500$  remuestreos con reemplazo):

$$\text{EES} = \min \left( \frac{\text{CRB}_\mu}{\widehat{\text{Var}}(\bar{\theta})}, 1 \right).$$

El sistema complementa este cómputo con una prueba de normalidad de Shapiro–Wilk [4] sobre  $\hat{\theta}$ : si el valor  $p$  resultante es menor a 0.05, se recomienda reportar el modelo Laplaciano (más robusto a colas pesadas) en lugar del gaussiano, y usar la mediana muestral —el estimador óptimo bajo ese modelo— en vez de la media.

**Observación 3.1.** La cota de Cramér–Rao certifica algo preciso y limitado: qué tan cerca está la *media muestral* de  $\hat{\theta}$  de ser un estimador óptimo de sí misma bajo un modelo

paramétrico supuesto. No certifica que  $\hat{\theta}$  mida “sentimiento real” correctamente, ni sustituye una validación externa (p. ej. contra anotación humana) del índice.

#### Hueco: qué NO certifica esta verificación

Bajo el modelo gaussiano con  $\sigma^2$  desconocida y estimada por  $\hat{\sigma}^2$ , la media muestral es el estimador insesgado de varianza mínima de  $\mu$  para todo  $N$  (Lehmann–Scheffé), con  $\text{Var}(\bar{\theta}) = \sigma^2/N$  exactamente. Es decir, bajo ese modelo la eficiencia es 1 por construcción, no por mérito del pipeline NLP-wavelet: no hay ningún estimador alternativo de  $\mu$  que pudiera ganarle a la media muestral. La comparación que hace el sistema — $\text{CRB}_\mu = \hat{\sigma}^2/N$  contra  $\widehat{\text{Var}}(\bar{\theta})$  estimada por *bootstrap sobre la misma muestra*— es, en el límite de  $N$  grande, una comparación entre dos maneras de estimar la *misma* cantidad ( $\sigma^2/N$ ) a partir de los *mismos* datos: la fórmula normal con  $\hat{\sigma}^2$  plug-in, y el remuestreo. Que ambas coincidan ( $\text{EES} \approx 1$ ) es entonces, en gran medida, una prueba de consistencia numérica entre bootstrap y la fórmula asintótica de la varianza de la media —algo que ocurre para casi cualquier muestra razonablemente grande, independientemente de qué tan bien el pipeline de embeddings y wavelets capture sentimiento real—, y *no* es evidencia de que el pipeline NLP-wavelet extraiga la máxima información posible del texto. Verificar eso último exigiría comparar  $\hat{\theta}$  contra una pipeline de extracción de características alternativa (o contra anotación humana) sobre el mismo texto, no solo verificar que la media muestral de  $\hat{\theta}$  es un buen estimador de sí misma. Sección 4 lo ilustra numéricamente: en la simulación,  $\text{EES} = 100\%$  a pesar de que  $\hat{\theta}$  rechaza normalidad (Shapiro–Wilk  $p < 10^{-3}$ ). Los textos de interpretación de la interfaz (`interpretar_crb` en `interpretacion.py`, y el “Marco Teórico” de `validacion.py`) sobreclamaban exactamente esto y ya fueron corregidos para reflejar el alcance real de la verificación.

### 3.4. Correlación con desempeño académico


Como paso final del análisis, el sistema calcula el coeficiente de correlación de Pearson  $r$  [6] entre  $\hat{\theta}_i$  y la calificación  $c_i$  de cada alumno, junto con su valor  $p$  asociado y el tamaño de muestra  $N$ . Una correlación negativa significativa ( $r < 0$ ,  $p < 0.05$ ) se interpreta como evidencia de que mayor carga emocional en las respuestas se asocia con menor desempeño; una correlación positiva significativa se interpreta como posible motivación extrínseca. El sistema clasifica la fuerza de la asociación en umbrales ( $|r| \geq 0.6$  fuerte,  $|r| \geq 0.3$  moderada,  $|r| < 0.3$  débil) y explícitamente reporta cuando la correlación no es significativa, sin forzar una narrativa de riesgo donde no hay evidencia estadística.

## 4. Resultados ilustrativos (simulación)


### Estas figuras son simulación, no datos de curso

Ningún dato de alumnos reales se usó para generar esta sección. Las señales, embeddings y calificaciones son sintéticas, construidas para ejercitar el código real de `processing/nlp_wavelet.py` y `processing/cramer_rao.py` —las mismas funciones que usa la aplicación— sobre entradas controladas, con el único fin de mostrar cómo se leen las gráficas que el sistema produce y de exhibir numéricamente el punto de la sección 3.3. La correlación de la figura 4 está impuesta por construcción en la simulación, no observada. Código de generación: `generar_figuras_articulo.py`.


Simulamos  $N = 60$  respuestas de longitud variable ( $L_i$  entero uniforme en  $\{12, \dots, 54\}$  tokens), cada una con una “intensidad emocional”  $e_i \sim \text{Gamma}(2, 0.5)$  que controla la amplitud de ráfagas locales insertadas en una tendencia de caminata aleatoria (figura 1), y una calificación simulada  $c_i = \text{clip}(92 - 9e_i + \eta_i, 40, 100)$  con  $\eta_i \sim \mathcal{N}(0, 6^2)$ , para poder ilustrar la lectura de una correlación negativa.




**Figura 1.** Dos señales posicionales simuladas  $s_i(t)$ : una con baja intensidad emocional impuesta (izquierda) y otra con ráfagas locales marcadas (derecha), que producen  $E^{\text{det}}$  bajo y alto respectivamente.



**Figura 2.** Distribución de  $\hat{\theta}$  sobre el grupo simulado ( $N = 60$ ). La asimetría visible es consistente con el rechazo de normalidad reportado en el texto (Shapiro–Wilk  $p < 10^{-3}$ ).



**Figura 3.** Distribución bootstrap de  $\tilde{\theta}$  ( $B = 500$ ) contra la banda  $\tilde{\theta} \pm \sqrt{\text{CRB}_\mu}$ . En esta simulación  $\text{EES} = 100\%$  a pesar de que  $\hat{\theta}$  rechaza normalidad — el punto central de la sección 3.3: esta cifra no mide si el pipeline extrae información del texto.



**Figura 4.** Correlación simulada entre  $\hat{\theta}$  y la calificación, impuesta por construcción ( $c_i$  se definió como función decreciente de la intensidad emocional simulada  $e_i$ ) para ilustrar cómo se lee esta gráfica en la interfaz real.

## 5. Discusión y limitaciones

El sistema es una herramienta de apoyo a la decisión docente, no un instrumento diagnóstico automatizado. El índice  $\hat{\theta}$  depende del modelo de embeddings elegido, de la familia y nivel de la wavelet, y del tamaño de la encuesta; con  $N < 30$  las estimaciones bootstrap de varianza son inestables y el propio sistema advierte de ello en la interfaz. Las interpretaciones textuales que genera el módulo `interpretacion.py` son sugerencias de lectura, no conclusiones definitivas, y deben cotejarse con el criterio del docente y, cuando el caso lo amerite, con apoyo psicopedagógico institucional. Como se documentó en sección 3.3, la verificación de Cramér–Rao certifica la coherencia estadística de  $\bar{\theta}$  bajo el modelo supuesto, no la calidad de  $\hat{\theta}$  como medida de sentimiento; esa segunda pregunta —la que de verdad importaría validar— queda abierta y requeriría comparación externa (anotación humana, u otra pipeline de extracción) sobre datos reales de curso, algo que este artículo deliberadamente no reporta.

### Implementación

Interfaz Streamlit (`app.py`) con cuatro páginas modulares (`pages/carga.py`, `pages/metricas.py`, `pages/sentimiento.py`, `pages/validacion.py`); `sentence-transformers` para embeddings, `PyWavelets` para la DWT, `scipy.stats` para Shapiro–Wilk y correlación de Pearson, `plotly` para visualización interactiva (incluyendo histograma bootstrap de  $\bar{\theta}$  con bandas  $\pm\sqrt{\text{CRB}}$ , comparación de varianzas, y gráfica Q–Q de  $\hat{\theta}$  contra la normal). Código y datos de ejemplo en [github.com/Gabriel44svg/Galindo-C.-J.-y-Villafuerte-C.-G.-2026-.SIAMDA](https://github.com/Gabriel44svg/Galindo-C.-J.-y-Villafuerte-C.-G.-2026-.SIAMDA).

## 6. Conclusión

Este sistema integra dos señales de un curso —calificaciones y respuestas abiertas de encuesta— bajo un mismo tablero, y añade a la segunda una métrica reproducible ( $\hat{\theta}$ , vía embeddings de token, proyección posicional y DWT) junto con una verificación estadística de la coherencia de su media agregada (información de Fisher y cota de Cramér–Rao, bajo modelos gaussiano y Laplaciano). El resultado es un sistema de alerta temprana que hace explícito, en vez de impresionista, el vínculo entre el tono de las respuestas de un grupo y su desempeño, y que documenta honestamente qué certifica su capa estadística y qué no. Queda como trabajo futuro la validación de  $\hat{\theta}$  contra anotación humana sobre datos reales de curso.

## Referencias

- [1] R. A. Fisher, *On the mathematical foundations of theoretical statistics*, Philos. Trans. R. Soc. Lond. A **222** (1922), 309–368.

- [2] C. R. Rao, *Information and the accuracy attainable in the estimation of statistical parameters*, Bull. Calcutta Math. Soc. **37** (1945), 81–91.
- [3] H. Cramér, *Mathematical Methods of Statistics*, Princeton University Press, 1946.
- [4] S. S. Shapiro and M. B. Wilk, *An analysis of variance test for normality (complete samples)*, Biometrika **52** (1965), no. 3/4, 591–611.
- [5] B. Efron, *Bootstrap methods: another look at the jackknife*, Ann. Statist. **7** (1979), no. 1, 1–26.
- [6] K. Pearson, *Mathematical contributions to the theory of evolution. III. Regression, heredity, and panmixia*, Philos. Trans. R. Soc. Lond. A **187** (1896), 253–318.
- [7] S. G. Mallat, *A theory for multiresolution signal decomposition: the wavelet representation*, IEEE Trans. Pattern Anal. Mach. Intell. **11** (1989), no. 7, 674–693.
- [8] N. Reimers and I. Gurevych, *Sentence-BERT: sentence embeddings using Siamese BERT-networks*, in Proc. 2019 Conf. Empirical Methods in Natural Language Processing (EMNLP-IJCNLP), Hong Kong, 2019, pp. 3982–3992.